Atlas Vivo — Informe académico de reproducibilidad

Estimación académica del valor del suelo rural de Yacopí, Cundinamarca · Rama `experimental/valor-terreno-ha` (commit `5cfabd6`) · generado el 2026-11-05 · Complemento de los cuadernos (no los sustituye)

1. Problema y observaciones del director

El profesor director requirió: (i) los cuadernos de análisis; (ii) trazabilidad de datos y decisiones; (iii) el código real de los algoritmos; (iv) aclarar qué se predijo en cada experimento pese a las dudas sobre la variable de respuesta; y (v) explicar los R^2 negativos y bajos del software. Este informe responde con evidencia reproducible, sin presentar un nuevo modelo definitivo.

2. Fuentes

`data/raw/interseccion_terrenos_zhg_r1_yacopi.csv` (9.447 filas × 17 columnas; avalúo, áreas, zonas ZHG) y `data/raw/zhf_yacopi.csv` (7.968 × 28; ZHF, CLC, coordenadas). Hashes SHA-256 y procedencia en `data/raw/data_manifest.json`. Fecha y vigencia de avalúos: no documentadas (pendiente con el docente).

3. Preparación de datos

Normalización de nombres y códigos → deduplicación (3 filas idénticas de intersecciones; 47 sobrantes ZHF) → unión por predio (7.694 con coincidencia; 15 solo intersección; 227 solo ZHF) → consolidación 1 fila/predio (**7.709 predios**) → banderas de calidad (1.601 multizona; 4.924 con |ZHF−catastral|>5 %; 46 áreas ≤100 m²; 3.033 con construcción). Código: `scripts/preparar_datos.py`, `scripts/build_db.py`, `scripts/audit_data.py`.

4. Variables objetivo de cada experimento

Experimento	Y	Construcción	n	Estado
exp-proxy-001 (Fase 2)	avalúo catastral TOTAL/ha (incluye obra)	proxy	7.694	histórico
exp-zhg-001 (Fase 5)	referencia ZHG zonal (11 valores)	solo zonas conocidas	7.709	rechazado
exp-zhg-001-ponderado	valor zonal ponderado (651 valores)	ídem	2.785	rechazado
exp-zhg-001-demo	referencia ZHG (sin evaluación independiente)	ajuste a todos	7.709	demo off
exp-valor-terreno-001 A	VALOR_AVALUO×10000/AREA_TERRENO (COP/ha)	construcción = 0	4.676	experimental
exp-valor-terreno-001 B	ídem	0 < construcción ≤ 32 m²	986	experimental
Oficial	valor exclusivo de suelo validado	—	—	503 pendiente

5. Construcción de modelos (código representativo)

Archivos reales: `ml/src/yacopi_ml/models.py` (Fase 2) y `ml/src/yacopi_ml/valor/train.py` (rama experimental).

```
forest = Pipeline([
    ("preprocess", preprocesador(X_train)),      # imputación + estandarización + one-hot
    ("model", RandomForestRegressor(n_estimators=400, max_depth=18,
                                    min_samples_leaf=3, random_state=SEED)),
])
forest.fit(X_train, y_train)
pred = forest.predict(X_test)                    # métricas con sklearn.metrics
```

Ridge entrena sobre `log1p(y)` y predice con `expm1`; CatBoost usa `cat_features` nativos (1.000 iteraciones, depth 6, lr 0,05). Transformaciones ajustadas SOLO con entrenamiento. Semillas: 42 (Fase 2/5) y 20261023 (rama experimental).

6. Métricas (protocolo v2: validaciones independientes)

Corrección de esta revisión: antes los modelos se entrenaban con la partición aleatoria y se evaluaban sobre el test espacial (81 % del test espacial de A y 80 % del de B ya estaban en el entrenamiento). Ahora cada protocolo entrena con su propio conjunto. Las cifras espaciales anteriores quedan archivadas como históricas no independientes.

VALOR_TERRENO_Ha (test por predio / test espacial independiente)

Escenario	Modelo	R² predio	R² espacial	MAE predio	MAE espacial
dummy_media	-0.000	-0.006	758,752	1,237,011	
ridge_log	0.302	0.011	392,022	838,996	
arbol	0.459	0.092	343,025	805,690	
random_forest	0.689	0.171	248,296	767,064	
catboost	0.725	-0.075	279,284	897,642	

Escenario	Modelo	R² predio	R² espacial	MAE predio	MAE espacial
dummy_media	-0.015	-0.087	15,347,647	6,175,772	
ridge_log	0.046	0.224	12,726,825	2,229,864	
arbol	0.118	0.618	11,846,090	1,149,744	
random_forest	0.146	0.863	11,487,894	932,873	
catboost	0.118	0.646	11,670,499	1,777,243	

ZHG Fase 5 (R² por predio vs zonas completas fuera)

Modelo	R^2 predio	R^2 zonas fuera	MAE predio	MAE zonas fuera
dummy	-0.16	-0.19	307,103	252,507
ridge	0.64	-0.32	168,433	238,760
tree	0.77	-0.17	93,033	273,318
forest	0.82	-1.70	73,765	423,363
catboost	0.78	-2.18	98,707	423,863

Comparación espacial del escenario A sobre los mismos 689 predios

Referencia	MAE (COP/ha)	MdAPE
Random Forest	767.064	11,69 %
Referencia ZHG del dataset	817.030	**5,65 %**
CatBoost	897.642	25,64 %

El menor MAE no implica el menor MdAPE: el MAE es sensible a pocos errores absolutos grandes; el MdAPE (mediana del error relativo) es robusto a ellos. RF gana el MAE (−6 % frente a la referencia ZHG) pero pierde el MdAPE (11,69 % vs 5,65 %): su mejora sobre el dato zonal es **limitada**.

Escenario B: los 7 valores extremos (> 50 M COP/ha por áreas mínimas) caen en el test por predios y no en el test espacial; por eso el protocolo predio muestra MAE ≈ 11,5–15,3 M y R^2 0,12–0,15, mientras el espacial independiente alcanza MAE 0,93 M (RF) y R^2 0,86. Son conjuntos de prueba con composición distinta: ambos se reportan.

7. Explicación de los R^2 negativos y bajos

$R^2 = 1 - \Sigma(y-\hat{y})^2 / \Sigma(y-\bar{y})^2$. $R^2 < 0 \Rightarrow$ el modelo supera en error cuadrático a la media del conjunto evaluado; no es un porcentaje de aciertos. Casos reales:

- **Baselines** (proxy −0,03/−0,02; dummy ≈ 0): la referencia media/mediana sobre un test distinto del entrenamiento da $R^2 \approx 0$ por construcción.
- **Ridge espacial −0,11 (proxy):** modelo lineal sobre objetivo sesgado, peor que la media en bloques geográficos nuevos.
- **ZHG zonas fuera −1,70 (RF) y −2,18 (CatBoost):** zonas 01/06/10 nunca vistas, con niveles propios; el modelo memoriza la zona y no extrapola.
- **LOZO −1e30/NaN:** subconjuntos con varianza casi nula → denominador ≈ 0 (R^2 indefinido).
- **Escenario B (R^2 0,12–0,15):** 7 predios de test > 50 M COP/ha por áreas mínimas dominan el error cuadrático.
- **v2 espacial A (CatBoost −0,075):** bloques geográficos no vistos en el entrenamiento (generalización espacial limitada).

Recálculo: `ml/src/yacopi_ml/valor/audit_r2.py` (sklearn `r2_score` sobre pares alineados y_true/y_pred) con protocolos independientes y asserts de disjuntez. Además, hoy se reentrenó por completo el experimento proxy y el ZHG: reproducen exactamente las cifras históricas de la interfaz y de Fase 5 (negativos incluidos). **El único defecto de evaluación identificado fue la validación espacial v1** (test contaminado, métricas infladas —no negativas—, corregidas y archivadas como no independientes). Los R^2 negativos reportados están calculados correctamente y responden a causas científicas, no a errores de programación.

Ejemplo didáctico corregido (figura 1): recta ajustada en x ∈ [0,2] de una parábola y evaluada en x ∈ [6,10] con entrenamiento y prueba separados → R^2 prueba = −18,55 (calculado por el código).

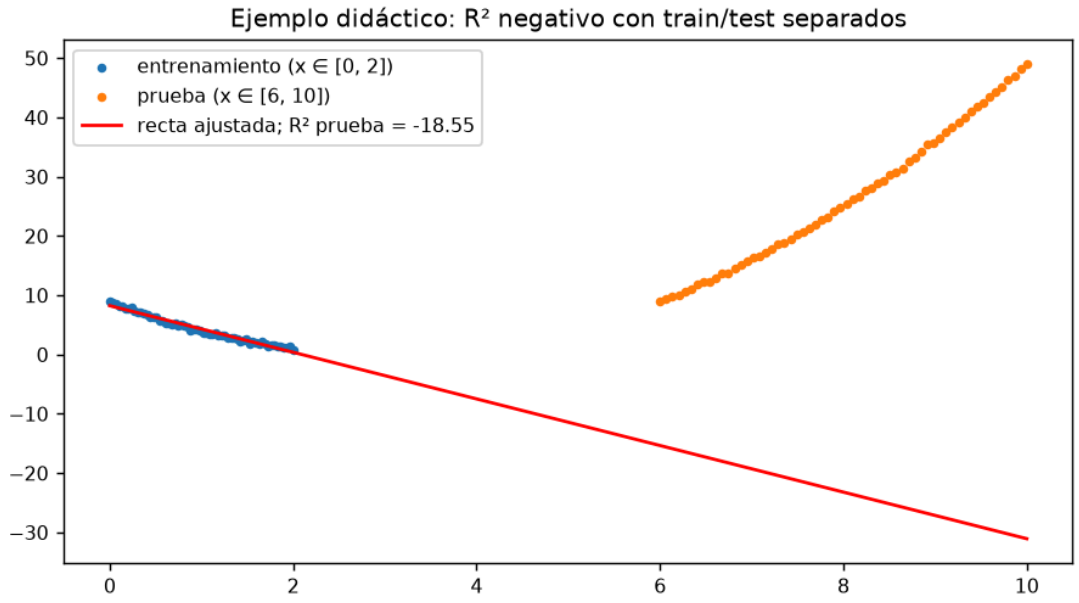


Figura 1 — R^2 negativo sin error de código: recta ajustada a una parábola (entrenamiento en x ∈ [0,2], prueba en x ∈ [6,10]; R^2 de prueba = −18,55).

8. Comparación por tipo de validación

La partición aleatoria infla R^2 por autocorrelación espacial (proxy RF: 0,82 → 0,74 al pasar a espacial; valor-terreno A RF: 0,69 → **0,17** en la validación espacial independiente). Con zonas completas fuera, los modelos ZHG colapsan (R^2 negativos) → rechazo con criterio predefinido. LOZO del escenario A: MAE 175 k–1,19 M por zona: el desempeño depende de que la zona esté representada.

9. Decisiones tomadas

- No entrenar modelo "oficial" sin etiqueta verificada (503).
- Proxy histórico solo como comparación metodológica, nunca elegible.
- Fase 5: criterio de aceptación predefinido → rechazo de los 5 modelos.
- Demo RF desactivada por defecto y distinguida de validación.
- Nueva variable del profesor auditada antes de modelar; umbral de 32 m² verificado sobre CONSTRUCCIÓN; extremos reportados sin eliminarlos.
- **Corrección de esta revisión:** validación espacial con entrenamiento propio (protocolo v2); métricas v1 archivadas como no independientes.

10. Limitaciones metodológicas

- Sin fecha/vigencia del avalúo ni del valor zonal.
- `valor_avaluo` es total (incluye construcción); no hay campo de suelo exclusivo.
- Áreas inconsistentes entre fuentes (4.924 predios > 5 %).
- Dependencia espacial fuerte; extremos por áreas mínimas sin criterio docente.
- Métricas ZHG de Fase 5 y proxy: verificadas hoy por reentrenamiento completo (reproducción exacta); la variante ponderada no se reentrenó.

- Consolidación: avalúo/áreas constantes por predio (0 inconsistentes); 12 predios (0,16 %) con zona dominante distinta de la primera registrada (corregido usando la zona dominante por área); sin crossover entre escenarios A y B.

11. Preguntas al docente

1. Fecha y procedencia de `valor_avaluo`.
2. ¿Avalúo total o exclusivo de terreno?
3. Confirmación del umbral de 32 m² sobre construcción.
4. Criterio para predios con área mínima (cocientes extremos).
5. Alcance interpretativo: ¿refinar la referencia zonal o fuente independiente?

12. Próximos pasos

Con las confirmaciones docentes: consolidar el escenario A (CatBoost/RF) como candidato experimental, definir el tratamiento de extremos, documentar el esquema de entrada FastAPI y solo entonces evaluar la habilitación del endpoint oficial (hoy 503).